

MBA
USP
ESALQ

Séries Temporais

Prof. Dr. Ricardo Limongi

Agenda

- Revisão da aula anterior
- ARIMA
- SARIMA
- Prophet


Luiz Rodriguez Fantini 005.374.619-81

Vimos na Aula Anterior...


- Séries Temporais
 - Conjunto de observações feitas em sequência ao longo do tempo
- Componentes:
 - Sazonalidade
 - Padrões de comportamento que se repetem em específicas épocas do ano
 - Tendência
 - Padrão de crescimento/decrescimento da variável em um certo período de tempo
 - Resíduo/Ruído
 - Capta os efeitos que não foram incorporados pela série de tempo, ou seja, o resíduo

Vimos na Aula Anterior...

Sazonalidade




Tendência



Vimos na Aula Anterior...

- Estacionariedade
 - Série não muda ao longo do tempo facilitando a previsão
 - Condições:
 1. Média constante e o desvio padrão sem efeito de sazonalidade
 2. Avaliação por meio do Teste de Dicky-Fuller
 3. Avaliação do p valor do teste




Vimos na Aula Anterior...

- Autocorrelação
 - Autocorrelação (ACF)
 - Relação existente entre as observações ao longo do tempo
 - Autocorrelação parcial (PACF)
 - Fornece a correlação parcial de uma série de tempo estacionária com seus próprios valores defasados regredindo os valores da série de tempo nas defasagens mais curtas. Contrasta com a função de autocorrelação, que não controla para outras defasagens.

Vimos na Aula Anterior...

- Autocorrelação



Vimos na Aula Anterior...

- Lags:
 - **Tempo de atraso** na série para calcular as correlações.
 - As defasagens são criadas após o deslocamento da série e, em seguida, compare a série defasada com a série original sem defasagem

Date	Value	Value _{t-1}	Value _{t-2}
1/1/2017	200	NA	NA
1/2/2017	220	200	NA
1/3/2017	215	220	200
1/4/2017	230	215	220
1/5/2017	235	230	215
1/6/2017	225	235	230
1/7/2017	220	225	235
1/8/2017	225	220	225
1/9/2017	240	225	220
1/10/2017	245	240	225

Ajustamento Exponencial

Suavização Exponencial Simples

sem tendência e sazonalidade, parâmetro α

Holt's Suavização Exponencial

com tendência , parâmetro α e β

Holt-Winter Suavização Exponencial

com tendência e sazonalidade, parâmetro α , β e γ

ARIMA

- **AR → Modelo Autoregressivo**

- A variável de interesse é uma regressão linear de valores passados da própria variável, o que implica que o futuro depende do passado. É composto por “p” observações defasadas da variável de interesse mais um ruído, que captura o que não é explicado pela regressão.

- **I → Integrado**

- Refere-se a diferentes métodos, computando diferenças entre observações consecutivas, para obter um processo estacionário a partir de um processo não estacionário. É definido pelo parâmetro “d”, que descreve o número de vezes que as observações são diferenciadas.

- **MA → Modelo de Média Móvel**

- É um modelo semelhante a uma regressão que recorre a erros de previsão anteriores para prever a variável de interesse, além de um ruído. A média móvel tem ordem “q” e define o tamanho da janela da média móvel.

ARIMA

ARIMA: Modelo Autoregressivo, integrado e de média móvel

Parâmetros

- P , termo autoregressivo
- D , número de diferenciações
- Q , termo da média móvel

ARIMA

AR: modelo autoregressivo AR (p) ou ARIMA (p,0,0):

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t$$

MA: apenas média móvel MA (q) ou ARIMA (0,q,0):

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q}$$

Junção de AR e MA: ARMA (p,q) ou ARIMA (p,0, q):

$$y'_t = c + \phi_1 y'_{t-1} + \cdots + \phi_p y'_{t-p} + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} + \varepsilon_t$$

Com a diferenciação: ARIMA (p,d,q)


Com a sazonalidade: ARIMA (p,d,q,) (P,D,Q)

SARIMA

SARIMA: Modelo Autoregressivo Sazonal, integrado e de média móvel

Parâmetros

- P , termo autoregressivo
- D , número de diferenciações
- Q , termo da média móvel
- M , período sazonal (período anual 12, quadrimestre 4,)



Procedimento para avaliação dos parâmetros

Eventuais transformações necessárias:

- Diferenças entre 1a ou 2a ordem para remover tendências
- Diferença para remover efeitos sazonais
- Transformação logarítmica em caso de não estacionariedade

Fonte: Box e Jenkins (1974)

Prophet

Baseado em modelo aditivo

$$y(t) = g(t) + s(t) + h(t) + \epsilon t$$

$g(t)$ = representa tendência

$s(t)$ = representa sazonalidade

$h(t)$ = representa os eventos

Prof. Dr. Ricardo Limongi



[linkedin.com/in/ricardolimongi/](https://www.linkedin.com/in/ricardolimongi/)